ИТ КоР 5.0 · Трек Machine Learning · Кейс 02

Нейросетевая аппроксимация широкодиапазонного уравнения состояния алюминия с учётом термодинамических ограничений

Итоговая документация решения

Капитан команды: Бронникова Екатерина Юрьевна
2026

Содержание

1. Постановка задачи и итоговый результат
2. Команда и роли
3. Архитектура решения и структура репозитория
4. Модуль 1. Данные, EDA и бейзлайн
5. Модуль 2. Нейросетевая модель (Vanilla)
6. Модуль 3. Учёт физических ограничений (PINN)
7. Модуль 4. Инференс и упаковка
8. Модуль 5. Сжатие и скорость работы
9. Установка и запуск
10. Выводы и ограничения
11. Ответы на ожидаемые вопросы жюри

1. Постановка задачи и итоговый результат

Уравнение состояния (УРС) вещества — ключевой компонент гидродинамических кодов физики высоких плотностей энергии: оно вызывается миллионы раз за расчёт и должно быть одновременно точным, быстрым и термодинамически корректным. По условию кейса требуется обучить физически информированную нейросеть (PINN), аппроксимирующую табличное полуэмпирическое УРС алюминия: по плотности ρ и температуре T вернуть давление P(ρ,T), удельную внутреннюю энергию E(ρ,T), частные производные $\partial P/\partial \rho$, $\partial P/\partial T$, $\partial E/\partial \rho$, $\partial E/\partial T$ и скорость звука c_s.

Итог. Построены две версии PINN одинаковой архитектуры (0.29 МБ, одна сеть на всю область $\rho \in [10^{-3}, 10^{4}]$ г/см³, $T \in [0.1, 10^{7}]$ K), между которыми явно измерен компромисс «точность ↔ термодинамика»:

- **PINN-T «термодинамическая» (рекомендуемая, т.к. по условиям организаторов приоритет — выполнение термодинамических ограничений):** невязка соотношения Максвелла 5 % (у самих таблиц — 49 %, т.е. в 10 раз согласованнее исходных данных), нарушения устойчивости 0.08 % точек, средняя ошибка по P и E ≈ 12 %.
- **PINN-A «точная»:** ошибка 0.36 % по P и 0.59 % по E, нарушения устойчивости 0.018 % (у обычной сети — 28.4 %), но по Максвеллу она так же несогласованна, как таблицы (47 %).

Обе модели экспортированы в ONNX и TorchScript, производные и c_s вычисляются внутри экспортированного графа; класс-обёртка EOSModel предоставляет методы predict, sound_speed, derivatives и check_physics (с флагом выхода за область обучения).

Ключевая находка исследования данных: исходные таблицы не удовлетворяют соотношению Максвелла $\rho^2 \partial E/\partial \rho = P - T\partial P/\partial T$ (медиана невязки 29 %, на холодной кривой — ровно в 2 раза). Поэтому условия устойчивости навязываются полностью, а термодинамическая согласованность — штрафом с количественно измеренным компромиссом точности.

Таблица 1 — Сводные результаты (ошибки — на test, нарушения — доля из 200 000 случайных точек по области; размер: state_dict и ONNX «только P,E» — 0.29 МБ, ONNX с производными и c_s — 0.59 МБ)

Модель	P, ср. ошибка	E, ср. ошибка	Нарушения устойчивости	Размер	10^5 запросов P, E
Билинейная интерполяция (ln P)	0.012 %	0.027 %	1.9 %	4.4 МБ	45 мс
Vanilla MLP	0.22 %	0.25 %	28.4 %	0.29 МБ	123 мс (ONNX)
PINN-T «термодинамическая»	**11.9 %**	**11.9 %**	**0.082 %**	**0.29 / 0.59 МБ**	**113 мс (ONNX)**
PINN-A «точная»	0.36 %	0.59 %	0.018 %	0.29 / 0.59 МБ	126 мс (ONNX)
Компактная PINN	1.0 %	1.4 %	0.048 %	0.06 МБ	45 мс (ONNX)

Таблица 2 — Выполнение термодинамических ограничений

Модель	|r_M| медиана (Максвелл)	Нарушения устойчивости	$\mathscr{G} < 0$ (выпуклость)	P, ср. ошибка
Таблицы (исходные данные)	0.49	1.9 %	2.2 %	—
Vanilla MLP	0.48	28.4 %	13.2 %	0.22 %
PINN-A «точная»	0.47	0.018 %	15.9 %	0.36 %
PINN-T «термодинамическая»	**0.050**	0.082 %	14.0 %	11.9 %

2. Команда и роли

Таблица 3 — Состав команды

№	ФИО	Роль
1	Бронникова Екатерина Юрьевна	Капитан команды. Архитектура PINN, физический лосс; документация, презентация, финальная сборка решения
2	Ярутов Алексей Николаевич	Загрузка данных, EDA, baseline (билинейная интерполяция)
3	Малицын Николай Романович	Обучение Vanilla-модели, подбор гиперпараметров
4	Боева Анастасия Владимировна	Физический блок: автоград производных, скорость звука
5	Семенова Анжелика Романовна	Инференс, упаковка (ONNX, TorchScript), класс-обёртка

3. Архитектура решения и структура репозитория

Решение оформлено как Python-пакет eos (переиспользуемая библиотека) и набор скриптов по модулям кейса; каждый скрипт можно запускать отдельно, run.py запускает весь пайплайн.

Таблица 4 — Модули репозитория

Файл	Назначение
eos/data.py	Загрузка 20 областей, восстановление сеток, разбиение train/val/test, класс Normalizer (JSON)
eos/baseline.py	BilinearEOS — билинейная интерполяция по каждой сетке в нативных координатах
eos/physics.py	Формулы c_s^2, невязки Максвелла, флаги нарушений, производные таблиц, случайные точки области
eos/metrics.py	Относительные ошибки P и E, метрики по областям
eos/model.py	EOSNet (Фурье-признаки + MLP), явный якобиан, Thermo, физические потери, экспортируемые модули
eos/train.py	Конфигурация и цикл обучения (Vanilla и PINN), чекпойнты
eos/wrapper.py	Класс-обёртка EOSModel: predict / derivatives / sound_speed / check_physics
scripts/m1_eda_baseline.py	Модуль 1: EDA, сечения, физика данных, бейзлайн, нормировка
scripts/m2_m3_train.py	Модули 2–3: обучение Vanilla, PINN, серия по весу Максвелла
scripts/m4_evaluate.py	Модуль 4: метрики, проверка autograd, экспорт, графики, таблица сравнения
scripts/m5_compress.py	Модуль 5: TorchScript, ONNX, fp16, int8, компактная модель, замеры
scripts/ m2_autograd_derivatives.py	П. 2.3: производные через torch.autograd во всех тестовых точках, сверка с явным якобианом
scripts/m3_extra_physics.py	Доп. проверки: выпуклость изоэнтроп $\mathscr{G} > 0$ и третье начало
scripts/m4_bench_1e8.py	Замер скорости на 10^8 запросов
configs/*.json	Гиперпараметры: vanilla, pinn_finetune_sweep, pinn (PINN-A), pinn_thermo (PINN-T), pinn_small, pinn_consistent (эксперимент с $\mathscr{G}$)
README.md, docs/README_Module1… 6.md	Главный README (запуск, метрики, API) и документация каждого модуля
tests/test_core.py	Тесты: якобиан = autograd, ONNX = PyTorch, проверка входа
examples/api_example.py	Пример использования API

4. Модуль 1. Данные, EDA и бейзлайн

4.1. Структура данных

Данные — 20 файлов Obl01…Obl20 (1 130 053 точки, колонки ρ [г/см³], T [K], P [ГПа], E [кДж/г]). Каждая область — полная прямоугольная сетка, равномерная по каждой оси либо линейно, либо логарифмически; встречаются все 4 типа: log-log (13 областей), log-lin (4), lin-log (4), lin-lin (1). Пропусков и дубликатов нет, на общих границах значения непрерывны.

Давление положительно и меняется на 12 порядков (от $5 \cdot 10^{-4}$ до $1.6 \cdot 10^{9}$ ГПа), энергия меняет знак (от −47 до $1.8 \cdot 10^{5}$ кДж/г). Поэтому целевые переменные сети — ln P и asinh(E / 1 кДж/г), входы — ln ρ и ln T. Удобное свойство единиц: ГПа / (г/см³) = кДж/г, и термодинамические соотношения записываются без коэффициентов.

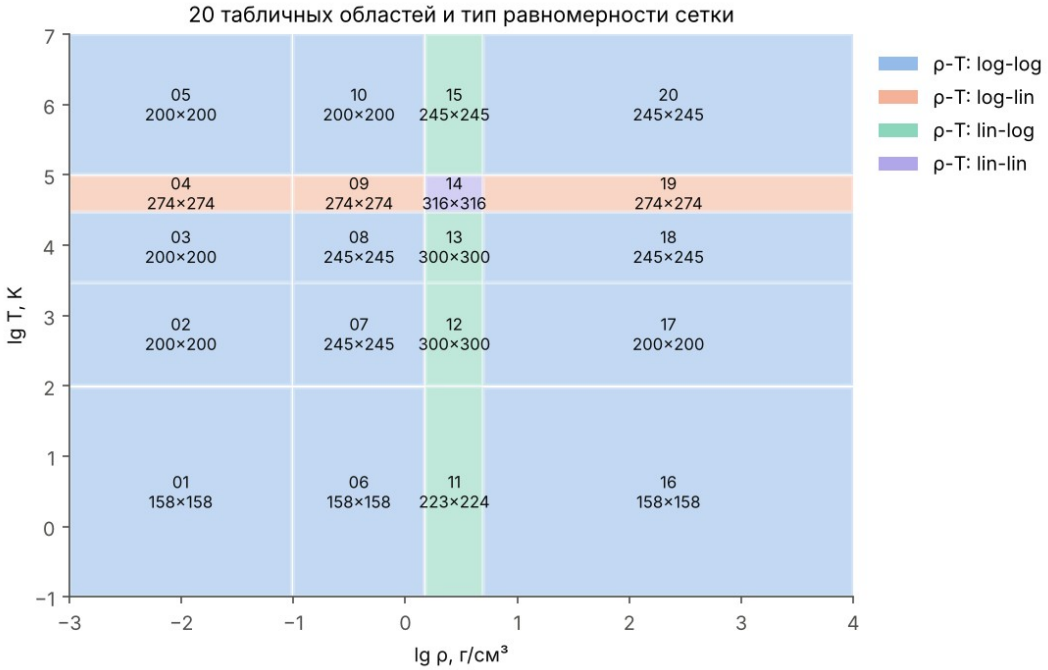


Рисунок 1 — 20 табличных областей и тип равномерности сетки

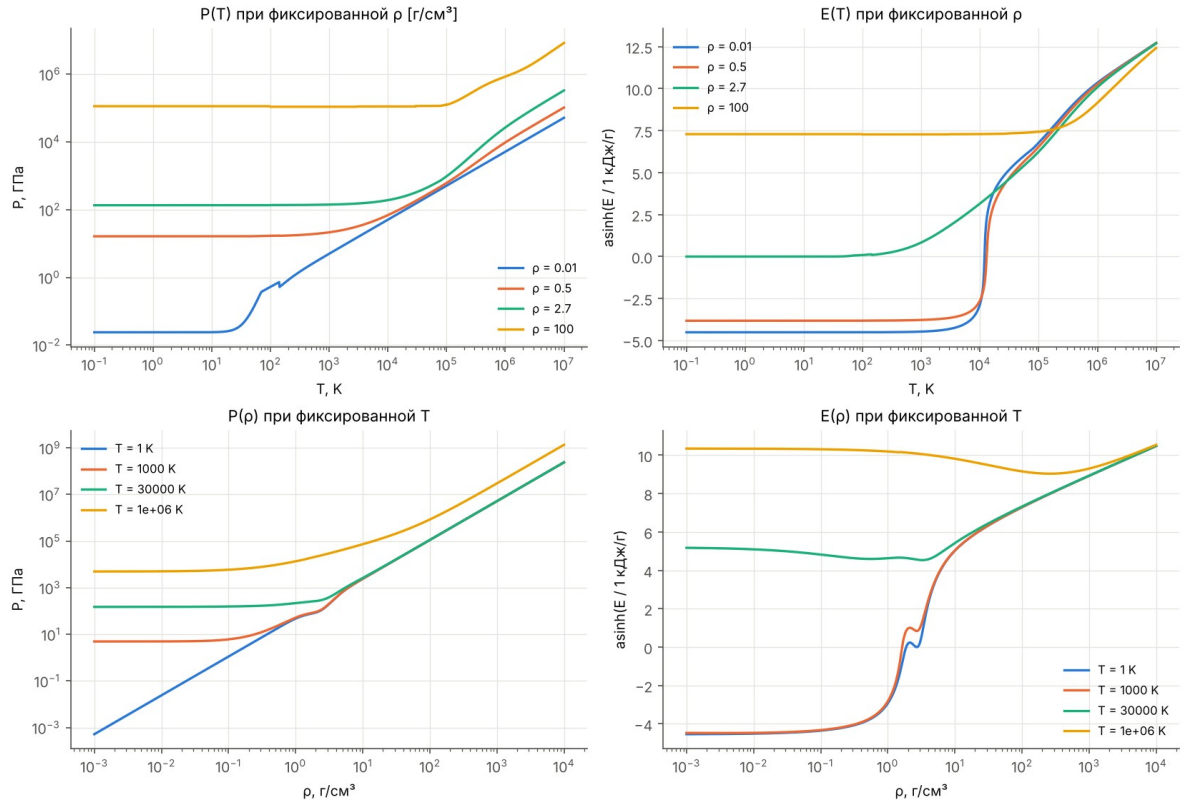


Рисунок 2 — Сечения P и E при фиксированных ρ и T

4.2. Проверка термодинамики на самих таблицах

Производные таблиц вычислены центральными разностями по узлам, затем проверены все ограничения кейса.

Таблица 5 — Термодинамические ограничения в табличных данных

Ограничение	Выполнение в данных
$(\partial P/\partial \rho)_T > 0$ — механическая устойчивость	везде
$C_v = (\partial E/\partial T)_\rho \geq 0$ — термическая устойчивость	везде, кроме линии $T \approx 143$ K (скачок E и P во всех областях)
$c_s^2 > 0$	везде, кроме той же линии
$c_s < c$	нарушается при $T \to 0$: E не зависит от T ($C_v = 0$), а $\partial P/\partial T \neq 0$
$\rho^2(\partial E/\partial \rho)_T = P - T(\partial P/\partial T)_\rho$ — соотношение Максвелла	не выполняется: медиана $\lvert r_M \rvert = 0.29$, у 70 % узлов > 5 %

На холодной кривой P ∝ ρ^{5/3} (вырожденный электронный газ), а $\rho^2 \partial E/\partial \rho$ ровно в два раза меньше P. Минимум холодной энергии находится при $\rho \approx 2.6$ г/см³, но давление там ≈ 140 ГПа, а не 0. Следовательно, таблицы P и E не происходят из одной свободной энергии. Для PINN это означает: условия устойчивости совместимы с данными и могут навязываться без потери точности, а условие Максвелла несовместимо с данными и может вводиться только как компромисс.

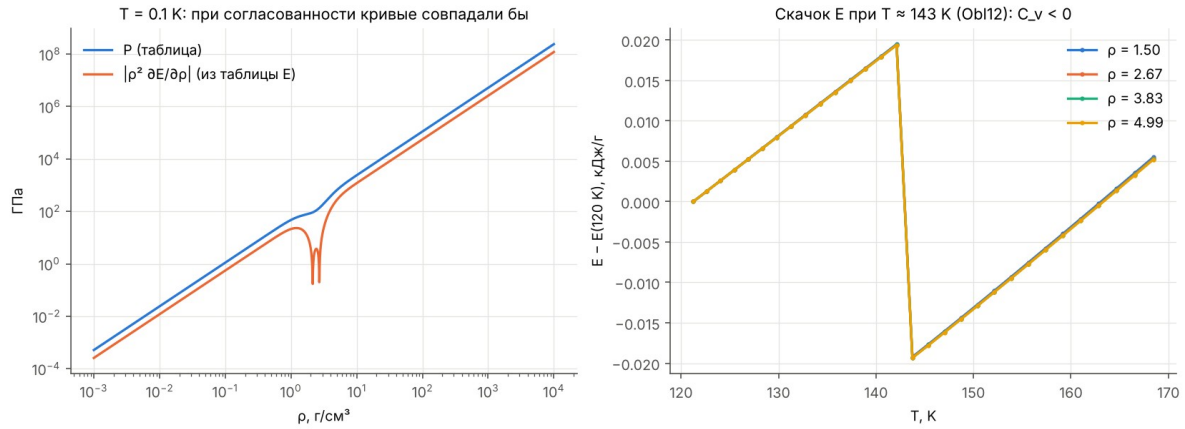


Рисунок 3 — Холодная кривая (несогласованность P и E) и скачок энергии при T ≈ 143 K

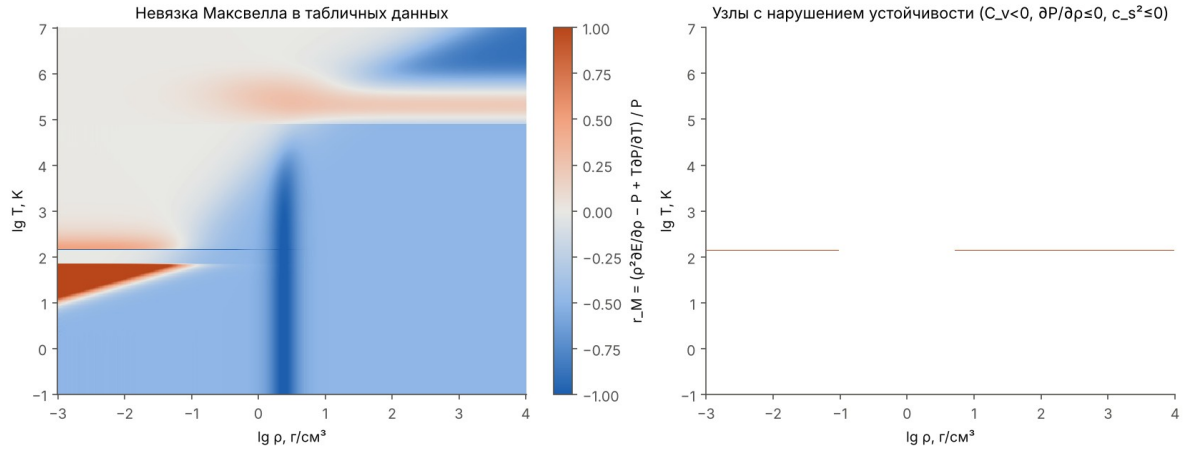


Рисунок 4 — Невязка Максвелла и узлы с нарушением устойчивости в табличных данных

4.3. Разбиение и нормирование

- **train** — узлы с чётными индексами по обеим осям (+ крайние узлы): 286 521 точка;
- **test** — центры ячеек train-сетки (нечётные индексы): 278 537 точек — самые трудные точки для интерполяции;
- **val** — середины рёбер: 564 995 точек.

И бейзлайн, и нейросети используют только train, что делает сравнение честным. Коэффициенты нормирования сохраняются в artifacts/models/normalization.json: x = (ln ρ − μ)/σ и (ln T − μ)/σ отображают область в [−1, 1]²; y_P = (ln P − μ_P)/σ_P; y_E = (asinh(E/E_s) − μ_E)/σ_E.

4.4. Бейзлайн — билинейная интерполяция

Для каждой из 20 областей строится билинейный интерполятор (scipy RegularGridInterpolator) в нативных координатах сетки: по ln для логарифмических осей и по самой величине для линейных — так в каждой ячейке интерполяция идёт по равномерной сетке. Варианты значений: P и ln P. Производные — центральными разностями.

Таблица 6 — Метрики бейзлайна

Метрика (test)	Интерполяция P	Интерполяция ln P
P, средняя относительная ошибка	0.055 %	0.012 %
P, 95-й перцентиль	0.20 %	0.013 %
P, максимум (скачок 143 K)	21.9 %	20.4 %
E, средняя относительная ошибка	0.027 %	0.027 %

Метрика (test)	Интерполяция P	Интерполяция ln P
Размер таблиц	4.4 МБ	4.4 МБ
10^5 запросов P, E / с производными	48 / 241 мс	45 / 228 мс
Доля нарушений устойчивости	1.9 %	1.9 %

5. Модуль 2. Нейросетевая модель (Vanilla)

Архитектура EOSNet: 32 случайных Фурье-признака sin/cos(πBx), B ~ N(0, 2^2) → 5 скрытых слоёв по 128 нейронов с активацией SiLU → 2 выхода (нормированные ln P и asinh E); 74 882 параметра. Гладкая активация необходима, так как производные выходов по входам используются в физических ограничениях. Давление восстанавливается как exp(·), поэтому P > 0 гарантировано конструктивно.

Таблица 7 — Подбор архитектуры

Вариант (100 эпох)	P, ошибка на val	E, ошибка на val
MLP 5×128, SiLU	2.0 %	2.4 %
MLP 4×256, SiLU	2.2 %	2.6 %
MLP 5×128, tanh	1.4 %	1.5 %
Фурье 16, σ = 1	0.77 %	1.1 %
Фурье 32, σ = 2 (выбран)	**0.53 %**	**0.84 %**
Фурье 64, σ = 3	0.55 %	0.85 %
Фурье 32, σ = 4	0.79 %	1.5 %

Фурье-признаки снимают спектральное смещение MLP и позволяют описать резкие переходы: ионизационный рост энергии около 10^4 K и структуру холодной кривой около нормальной плотности. Обучение: Adam, шаг $2\cdot10^{-3}$ → 10^{-5} по косинусу, батч 4096, 300 эпох, ограничение нормы градиента 1.

Производные через autograd (п. 2.3). Частные производные ∂P/∂ρ, ∂P/∂T, ∂E/∂ρ, ∂E/∂T и c_s^2 вычисляются через torch.autograd по физическим входам ρ и T (функция eos.model.autograd_derivatives, метод EOSModel.derivatives_autograd) во всех 278 537 тестовых точках — скрипт scripts/m2_autograd_derivatives.py, результаты в artifacts/tables/autograd_derivatives_*.csv.

Для инференса используется математически эквивалентный способ — явный якобиан (метод forward_jac протаскивает касательные векторы через слои за один проход). Он нужен потому, что autograd не экспортируется в ONNX, а гидрокоду производные и c_s нужны прямо в модели. Расхождение с autograd на всех тестовых точках — медиана $4\cdot10^{-7}$…$8\cdot10^{-7}$ (точность float32), в тестах — до 10^{-12} в double. В обучении PINN способ выбирается параметром deriv ("autograd" или "jac").

Результат Vanilla: 0.22 % по P и 0.25 % по E на test, но 28.4 % случайных точек области нарушают устойчивость ($C_v < 0$ — 25 %, ∂P/∂ρ ≤ 0 — 3.6 %, $c_s^2 \le 0$ — 2.5 %).

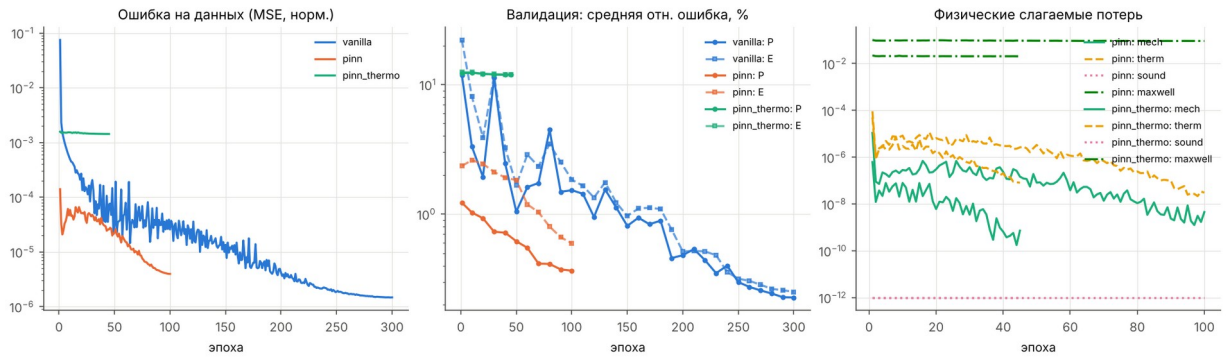


Рисунок 5 — Кривые обучения PINN (дообучение) — ошибка на данных, валидация и физические слагаемые

6. Модуль 3. Учёт физических ограничений (PINN)

Функция потерь L = L_data + λ·L_phys. Все физические слагаемые безразмерны и записаны через g_r = ∂lnP/∂lnρ, g_T = ∂lnP/∂lnT, e_r = ∂E/∂lnρ, e_T = ∂E/∂lnT = T·C_v, поэтому одинаково работают при P ~ 10^{-3} и 10^{9} ГПа.

Таблица 8 — Физические слагаемые функции потерь

Ограничение	Слагаемое потерь	Вес
(∂P/∂ρ)_T > 0	relu(ε − g_r), линейный hinge	1
C_v ≥ 0	relu(ε − ∂y_E/∂x_T), линейный hinge	1
c_s < c (п. 3.3)	relu(ln(c_s²/c²))² в точках с C_v > 0	0.1
Максвелл	Huber(r_M, δ = 0.5), r_M = ρe_r/P − 1 + g_T	λ_M

- Штрафы считаются на train-узлах и на 2048 случайных коллокационных точках на шаг по всей области — нарушения Vanilla возникают именно между узлами.
- Линейный hinge выбран потому, что нарушения C_v < 0 у Vanilla многочисленны, но малы по величине; квадратичный штраф почти не даёт для них градиента.
- Прямой штраф за c_s² < 0 исключён: при C_v → 0 тепловой член c_s² ∝ 1/C_v взрывается и разрушает обучение (в первой версии ошибка доходила до 100 %). Положительность c_s² следует из первых двух условий.
- PINN дообучается из весов Vanilla (сначала форма поверхности, затем физика) — в разы дешевле обучения с нуля, так как шаг PINN примерно в 10 раз дороже.

6.1. Компромисс точности и согласованности по Максвеллу

Таблица 9 — Серия дообучений PINN (50 эпох) с разным весом условия Максвелла

λ_M	P, % (test)	E, % (test)	Медиана |r_M|	Наруш. устойчивости
0	0.45	0.87	0.48	0.06 %
10^{-4} (выбран)	**0.43**	**0.88**	**0.47**	**0.12 %**
10^{-3}	0.63	0.97	0.44	0.06 %
10^{-2}	3.2	3.0	0.23	0.13 %
10^{-1}	12.4	12.7	0.06	0.18 %

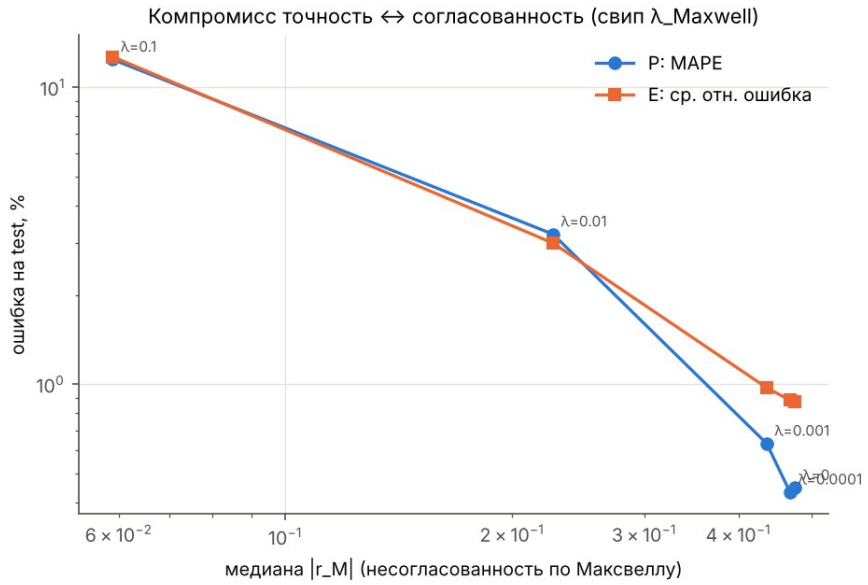


Рисунок 6 — Компромисс точность ↔ согласованность по Максвеллу

Согласованность по Максвеллу достижима только ценой отхода от таблиц — это свойство данных, а не метода. По итогам серии выбраны две финальные модели: **PINN-A** ($\lambda_M = 10^{-4}$, затем 100 эпох дообучения, шаг $10^{-4} \to 10^{-6}$) — максимум точности при полной устойчивости; **PINN-T** ($\lambda_M = 10^{-1}$, затем 45 эпох с утроенными штрафами устойчивости и 4096 коллокационными точками) — максимум термодинамической согласованности. Так как организаторы указали, что выполнение термодинамических ограничений важнее всего, рекомендуемой считается PINN-T.

6.2. Сравнение PINN с базовыми моделями

Таблица 10 — Итоговое сравнение (у бейзлайна дополнительно $c_s \geq c$ в 1.7 % точек; у сетей $c_s \geq c$ — 0 %)

Модель	P ср.	P 95 %	E ср.	E 95 %	Наруш.	C_v<0	∂P/∂ρ≤0	c_s²≤0	|r_M|
Билинейная (ln P)	0.012 %	0.013 %	0.027 %	0.085 %	1.9 %	0.19 %	0 %	0.08 %	0.49
Vanilla	0.22 %	0.59 %	0.25 %	0.82 %	28.4 %	25.0 %	3.6 %	2.5 %	0.48
PINN-A «точная»	0.36 %	1.08 %	0.59 %	1.98 %	**0.018 %**	0.016 %	0.002 %	0.015 %	0.47
PINN-T «термодин.»	11.9 %	34.6 %	11.9 %	37.8 %	0.082 %	0.081 %	0.0005 %	0.063 %	**0.050**

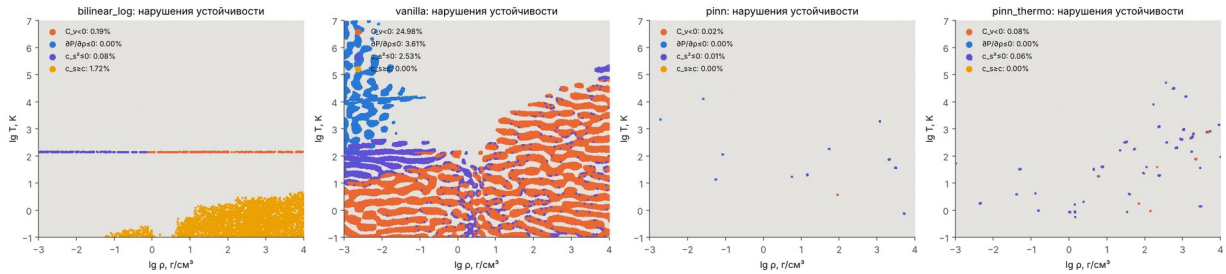


Рисунок 7 — Карты нарушений устойчивости на 200 000 случайных точек

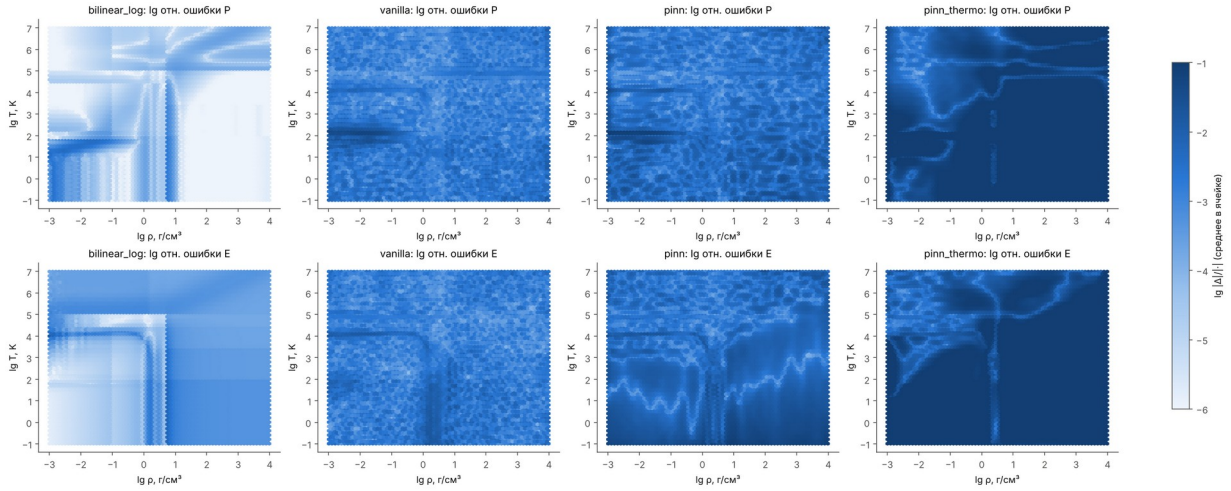


Рисунок 8 — Тепловые карты относительных ошибок P и E на test

PINN-A уменьшает долю нарушений устойчивости примерно в 1500 раз ценой 0.15–0.35 п.п. средней точности. PINN-T дополнительно уменьшает невязку Максвелла в 10 раз относительно самих таблиц, но отходит от них в среднем на 12 % (наибольшие отклонения — на холодной кривой, где таблицы P и E расходятся вдвое). Рост ошибки E у PINN-A сосредоточен при $T < 10^3$ K: монотонная по температуре модель не может повторить скачок энергии вниз при $T \approx 143$ K и сглаживает его — это сознательный выбор в пользу физики (см. п. 11).

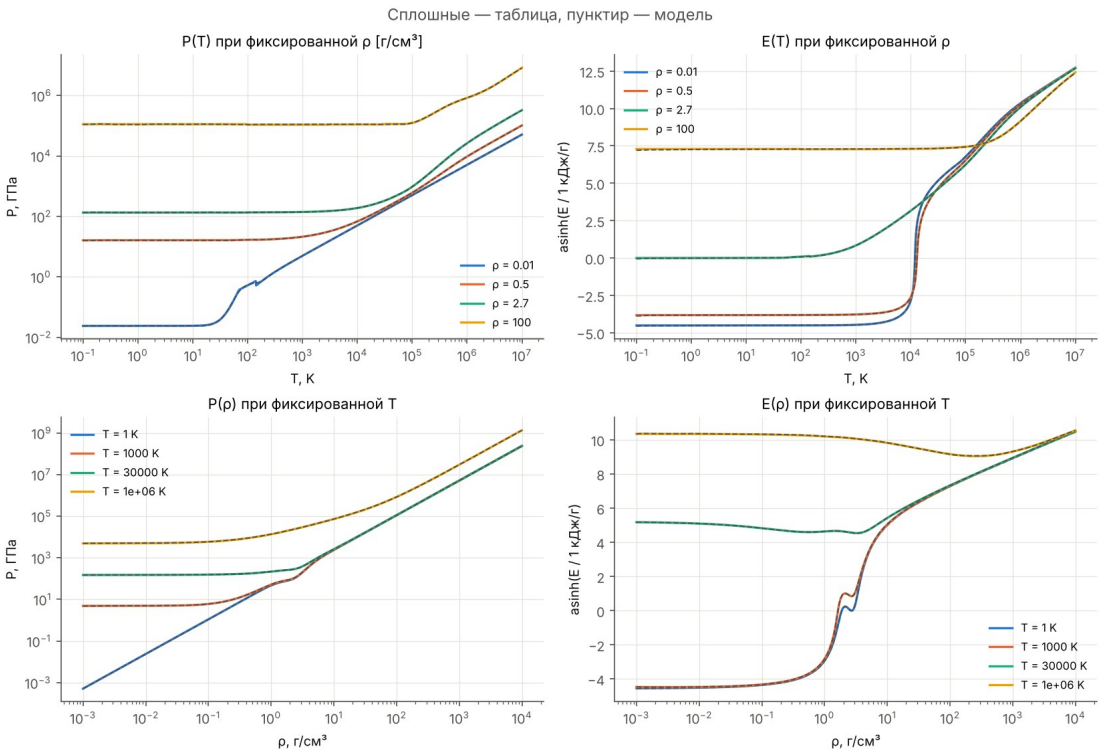


Рисунок 9 — Сечения: таблица (сплошные) и PINN-A (пунктир)

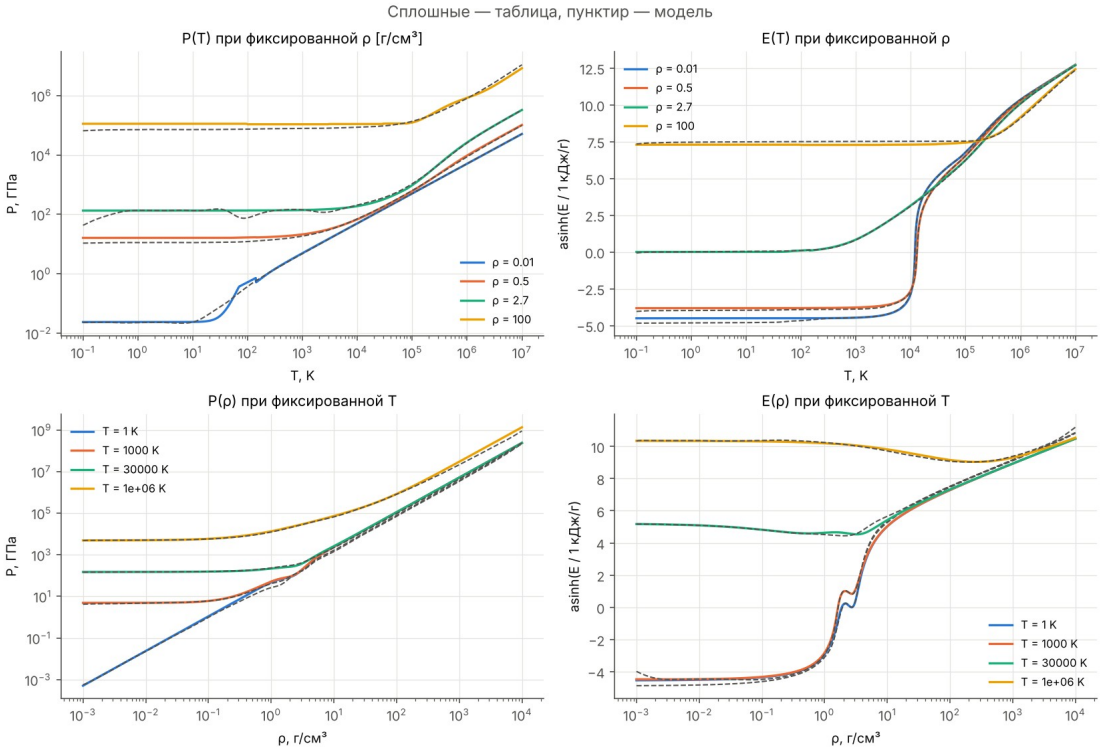


Рисунок 10 — Сечения: таблица (сплошные) и PINN-T (пунктир)

6.3. Дополнительные ограничения: выпуклость изоэнтроп и третье начало

Помимо условий из ТЗ проверены ещё два условия (scripts/m3_extra_physics.py). **Фундаментальная производная** $\mathcal{G}$ = 1 + (ρ/c_s)(∂c_s/∂ρ)_S > 0 (выпуклость изоэнтроп, условие Бете–Вейля): при $\mathcal{G}$ < 0 возможны ударные волны разрежения, что приводит к нефизичным решениям в гидрокоде. **Третье начало** (Нернст): при T → 0 должно быть C_v → 0 и ∂P/∂T → 0.

Таблица 11 — Дополнительные термодинамические проверки (100 000 случайных точек)

Модель	$\mathcal{G}$ < 0, % точек	|∂lnP/∂lnT| при T < 1 K (медиана / 95 %)
Таблицы (разности по узлам)	2.2 %	0 / 0
Vanilla	13.2 %	0.015 / 0.051
PINN-A	15.9 %	0.025 / 0.085
PINN-T	14.0 %	0.027 / 0.180

Это **открытая проблема** решения: выпуклость изоэнтроп у всех сетей нарушена заметно чаще, чем у таблиц (в основном при T < 10^5 K, где C_v мала и параметр Γ = P·g_T/(ρ·e_T) велик). Штраф за $\mathcal{G}$ < 0 реализован (параметр lam_conv, функция eos.model.fundamental_derivative), но в эксперименте за 20 эпох ошибка выросла до 20 % по P и 33 % по E (лог: artifacts/models/pinn_convexity_attempt.log), поэтому в финальные модели он не включён. Третье начало сети выполняют приближённо: при T < 1 K ∂lnP/∂lnT ≈ 0.02–0.03 вместо 0.

7. Модуль 4. Инференс и упаковка

- **Размер (п. 4.1):** state_dict 0.29 МБ (74 882 параметра); ONNX «только P, E» (pinn_predict.onnx) — 0.29 МБ; ONNX с производными и c_s (pinn.onnx) — 0.59 МБ (в

граф развёрнут расчёт якобиана, веса хранятся дважды — в прямом и транспонированном виде). Всё в 17–35 раз меньше лимита 10 МБ.

- **Скорость (п. 4.2):** 10^5 случайных запросов P, E — 113–126 мс в ONNX Runtime, с производными и c_s^2 — 0.7–0.8 с (CPU, 2 ядра). Дополнительно прогнано 10^8 запросов батчами по 10^6: PINN — 184 с (1.8 мкс/запрос), компактная PINN — 65 с, билинейная таблица — 45 с (artifacts/tables/bench_1e8.json).
- **Экспорт (п. 4.3):** pinn.onnx (P, E, 4 производные, c_s^2), pinn_predict.onnx (P, E), pinn.ts.pt (TorchScript), pinn_state_dict.pt; ONNX совпадает с PyTorch по P до точности float32.
- **Класс-обёртка (п. 4.4):** EOSModel — см. пример ниже.
- **Таблица сравнения (п. 4.5):** artifacts/tables/comparison.md и .csv.

```
from eos.wrapper import EOSModel
eos = EOSModel("artifacts/models/pinn_thermo.onnx")  # или pinn.onnx (PINN-A); ood="nan"
— NaN вне области
P, E  = eos.predict(rho, T)          # ГПа, кДж/г
d     = eos.derivatives(rho, T)      # dPdr, dPdT, dEdr, dEdT (= C_v), cs2
cs    = eos.sound_speed(rho, T)      # км/с (NaN, если c_s² ≤ 0)
flags = eos.check_physics(rho, T)    # True = нарушение: P_le0, dPdrho_le0, Cv_lt0,
cs2_le0, cs_ge_c, maxwell, out_of_domain
```

Проверки входа: ValueError при ρ ≤ 0, T ≤ 0, NaN/inf или разной форме массивов. Вне области обучения сеть экстраполирует и физику не гарантирует (например, при ρ = 10^5 г/см³ давление получается меньше, чем при 10^4), поэтому выдаётся RuntimeWarning, check_physics возвращает флаг out_of_domain, а режим EOSModel(..., ood="nan") возвращает NaN, как табличная интерполяция. Пример работы PINN-A (python examples/api_example.py):

```
ρ=0.01   T=1e+04 → P=50.23 ГПа    E=-8.392 кДж/г  c_s=741 км/с  устойчиво=True  r_M=-0.027
ρ=2.7    T=300   → P=136 ГПа      E=0.2407 кДж/г  c_s=10.6 км/с устойчиво=True  r_M=-0.986
ρ=2.7    T=1e+05 → P=956.8 ГПа    E=258.5 кДж/г   c_s=26 км/с   устойчиво=True  r_M=+0.074
ρ=100    T=1e+06 → P=8.354e+05 ГПа E=4685 кДж/г   c_s=125 км/с  устойчиво=True  r_M=-0.505
ValueError: rho и T должны быть конечными и > 0
```

Невязка r_M = −0.986 в точке ρ = 2.7 г/см³, T = 300 K — не ошибка модели: у самой таблицы в этой точке r_M = −0.988. Рядом находится минимум холодной энергии ($\rho^2 \partial E/\partial \rho \approx 0$), а табличное давление ≈ 136 ГПа, и PINN-A точно воспроизводит эту несогласованность данных. У PINN-T невязка здесь меньше (−0.76) — ценой отхода от табличных значений; сильнее всего PINN-T отходит от таблиц именно в холодных областях (T < $3\cdot10^3$ K, ошибка 20–33 %), а при T > $3\cdot10^4$ K её ошибка 0.5–3 %.

8. Модуль 5. Сжатие и скорость работы

Таблица 12 — Сжатие и ускорение (10^5 случайных запросов, CPU 2 ядра; «=» — та же модель)

Вариант	Размер, МБ	P,E, мс	+произв., мс	P, %	E, %	Наруш., %
PINN eager, autograd	0.29	436	952	0.36	0.59	0.017
PINN eager, явный якобиан	0.29	436	927	0.36	0.59	0.017
PINN TorchScript	0.29	165	612	=	=	=
PINN ONNX Runtime	0.59	125	785	=	=	=
Веса fp16 (хранение)	0.15	436	927	0.38	0.59	0.55
int8 dynamic quantization	0.08	290	—	11.8	11.2	—
Компактная PINN 64×4	**0.06**	102	**203**	1.0	1.4	0.048
Компактная PINN, ONNX	0.13	**45**	244	=	=	=
Бейзлайн (таблица)	4.4	45	228	0.012	0.027	1.9

- TorchScript (freeze + optimize_for_inference) ускоряет расчёт значений в 2.6 раза, ONNX Runtime — в 3.5 раза без потери точности.
- Хранение весов в fp16 вдвое уменьшает файл, но шум округления возвращает нарушения устойчивости (0.017 % → 0.55 %): после любого сжатия PINN физику необходимо перепроверять (check_physics).
- Динамическая int8-квантизация неприемлема: ошибка 11 %.
- Компактная PINN (≈ 15 тыс. параметров), обученная с теми же физическими потерями, в 4.8 раза меньше и в 4.6 раза быстрее по производным; по скорости значений в ONNX она равна таблице, которая весит в 70 раз больше.

9. Установка и запуск

```
pip install -r requirements.txt
# положить Obl01.txt … Obl20.txt в data/raw/
python run.py                 # весь пайплайн (CPU, ≈ 1.5–2 ч)
python run.py --skip-train    # только оценка и экспорт обученных моделей
python run.py --fast          # дымовой прогон
pytest -q                     # тесты
```

- python scripts/m1_eda_baseline.py — модуль 1 (EDA, бейзлайн, нормировка);
- python scripts/m2_m3_train.py --config configs/vanilla.json | pinn.json | pinn_thermo.json | pinn_small.json — обучение;
- python scripts/m2_m3_train.py --config configs/pinn_finetune_sweep.json --sweep-maxwell 0 1e-4 1e-3 1e-2 1e-1 — серия по λ_M;
- python scripts/m2_autograd_derivatives.py — производные через autograd в тестовых точках (п. 2.3);
- python scripts/m4_evaluate.py — оценка, экспорт, графики, таблица сравнения;
- python scripts/m5_compress.py — сжатие и ускорение;
- python scripts/m3_extra_physics.py — выпуклость изоэнтроп и третье начало; python scripts/m4_bench_1e8.py — 10^8 запросов.

10. Выводы и ограничения

- Одна нейросеть 0.29 МБ заменяет 20 таблиц и выдаёт P, E, все производные и c_s на всей области.
- PINN-A практически устраняет нарушения термодинамической устойчивости (28.4 % → 0.018 %) при точности 0.36 % / 0.59 %; PINN-T дополнительно в 10 раз согласованнее таблиц по Максвеллу (невязка 5 %) ценой ~12 % ошибки.
- Исходные таблицы термодинамически несогласованны; компромисс между точностью и согласованием по Максвеллу измерен явно и вынесен в параметр λ_M.
- Ограничения: точность в узлах ниже, чем у интерполяции; при $T < 10^3$ K модель сглаживает скачок энергии при 143 K; c_s при T → 0 определяется малым C_v.
- Открытая проблема: выпуклость изоэнтроп $\mathscr{G} > 0$ нарушена у сетей в 14–16 % точек (у таблиц 2.2 %).
- Развитие: согласовать P и E с авторами таблиц; выход сети — свободная энергия F(ρ,T) (см. п. 11); штраф за $\mathscr{G} < 0$ с более долгим обучением; дистилляция и GPU-инференс для гидрокода.

11. Ответы на ожидаемые вопросы жюри

Достаточна ли точность 0.36 % / 1–2 % (95-й перцентиль) для гидрокода?

Для типичных расчётов ФВПЭ погрешность самих полуэмпирических УРС составляет проценты, поэтому PINN-A с ошибкой ниже 1 % в 95 % точек сопоставима с точностью исходной модели. Важнее, что PINN даёт гладкие (C^∞) производные без скачков на границах ячеек и почти не нарушает устойчивость — именно разрывы производных табличной интерполяции чаще всего порождают численные осцилляции. Улучшать точность без потери физики можно увеличением ширины сети (лимит 10 МБ позволяет ×30), обучением на всех узлах таблицы (сейчас только на 25 % для честной оценки) и разбиением области на 2–3 специализированные подсети.

Скачок при 143 K — это фазовый переход? Не вредно ли его сглаживание?

Это не плавление: алюминий плавится при 933 K. Скачок E и P при 143 K присутствует одинаково на всех плотностях, от 10^{-3} (газ) до 10^{4} г/см³, и даёт C_v < 0 — физический фазовый переход первого рода проявлялся бы плато E(T) с C_v → ∞, а не падением энергии. Поэтому скачок интерпретирован как артефакт сшивки полуэмпирической модели, и сглаживание является исправлением. Если эксперты подтвердят, что это реальный переход, его можно учесть явно: добавить признак (T − T_пер) или обучать две подсети по обе стороны перехода с условием на скрытую теплоту.

Почему 10^5, а не 10^8 запросов?

В ТЗ (слайд 7) рекомендовано 10^5 запросов. Для надёжности дополнительно прогнано 10^8 запросов батчами по 10^6: время растёт линейно (184 с для PINN, 65 с для компактной PINN, 45 с для таблицы).

Почему сеть медленнее таблицы на CPU и зачем она тогда нужна?

На 2 ядрах CPU табличный поиск действительно быстрее основной PINN (компактная PINN сравнялась с таблицей). Преимущества сети: размер (0.29 МБ против 4.4 МБ прореженной и ~17 МБ полной таблицы), гладкие производные и выполнение термодинамических ограничений (таблица нарушает устойчивость в 1.9 % точек). На GPU плотные матричные умножения векторизуются эффективнее, чем нерегулярный доступ к памяти по 20 разным сеткам, — это ожидаемое, но в рамках работы не измеренное преимущество.

Почему не обучали сеть, выдающую свободную энергию F(ρ,T)?

Тогда P = ρ²∂F/∂ρ и E = F − T∂F/∂T, и соотношение Максвелла выполняется точно. Мы этого не делали по двум причинам. (1) Таблицы P и E несогласованны (на холодной кривой — вдвое), поэтому такая модель заведомо не сможет описать обе величины; PINN-T с невязкой 5 % уже показывает цену согласованности (~12 %). (2) Градиенты F по ln ρ и ln T меняются на 7 порядков по области, а E = F − T∂F/∂T при высоких T вычисляется как разность больших близких чисел; удобнее параметризовать функцию Массье Ψ = F/T, для которой E = −T·∂Ψ/∂lnT и P = ρT·∂Ψ/∂lnρ — это следующий шаг развития решения.

Почему 32 Фурье-частоты, а не 64?

64 частоты не улучшают точность (0.55 % против 0.53 % по P) и добавляют высокочастотный шум, а 32/σ = 4 ухудшают её до 0.79 %: 32 частоты при σ = 2 — оптимальный баланс между описанием резких переходов и гладкостью.

Почему размер модели указан как 0.29 и 0.59 МБ?

0.29 МБ — state_dict, TorchScript и ONNX «только P, E»; 0.59 МБ — ONNX с явным расчётом производных и c_s (в граф развёрнут якобиан, поэтому веса хранятся и в транспонированном виде). Обе величины многократно меньше лимита 10 МБ.